

基于跨任务注意力与二分类初始化的 DR/DME 联合分级系统

Rosen Luo

2026/06/29

Abstract

糖尿病视网膜病变（DR）与糖尿病性黄斑水肿（DME）在眼底病灶上存在显著相关性，适合通过共享表示进行联合建模。本文围绕 Messidor 数据集中病变程度四级分级与黄斑水肿风险三级分级两个监督任务，构建了基于 ConvNeXt-Tiny 主干、疾病特异注意力和跨疾病注意力的多任务识别系统。针对小样本长尾分布问题，我们系统比较了序数回归与类别敏感学习两条技术路线，并提出 binary-init 微调策略——先训练模型对阴性和阳性的二分类，再进行完整等级微调。五折交叉验证与多组消融实验表明：(1) CORN 在有序稳定性上更优，softmax+LDAM 对中间类别召回更敏感；(2) binary-init+CORN 取得最佳综合表现（DR QWK 0.9072，ME QWK 0.8787，balanced 0.8383）；(3) 延迟重加权（DRW）对训练稳定性至关重要，去除后会显著影响五折训练效果；(4) 叠加热力图分析表明 softmax+LDAM 更易受视盘亮区干扰，为后续健壮性增强提供了方向。

1.引言

糖尿病视网膜病变是糖尿病患者视力下降和致盲的重要原因。临床筛查通常需要同时判断视网膜病变程度与黄斑水肿风险：前者反映全局病变严重程度，后者与中心视力损害密切相关。自动眼底图像识别方法能够降低人工阅片压力，并为早筛提供一致、可扩展的辅助工具。

本研究聚焦 Messidor 数据集的联合任务：DR grade 0–3 四分类与 macular edema risk 0–2 三分类。与单任务分类相比，联合建模具有两个优势：(1) DR 与 DME 共享微动脉瘤、出血、硬性渗出等病灶线索，共享主干可以提高小数据条件下的样本效率；(2) 二者具有临床相关性，跨任务注意力可以显式建模一个任务对另一个任务的引导关系。

本文的主要贡献如下：

1. 构建了一个面向 DR+DME 联合分级的多任务网络，使用 ConvNeXt-Tiny 主干、疾病特异注意力和跨疾病注意力联合输出两个任务结果；
2. 系统比较了 CORN 序数头与 softmax+LDAM+DRW 在有序稳定性和中间类召回上的差异，揭示了两类训练目标的互补性；
3. 提出并验证 binary-init 微调策略：先训练 0-vs-positive 二分类边界，再加载共享主干与注意力模块进行完整等级微调；
4. 通过多组消融实验（DRW 延迟策略、early stopping 指标选择、LDAM margin 调度方式、backbone 选择）全面验证各设计选择的必要性；
5. 结合 Grad-CAM 可解释性分析，揭示 softmax 方向的视盘亮区误激活风险。

2.相关工作

2.1 眼底图像 DR 分级

深度卷积网络已广泛用于 DR 自动分级。ResNet、EfficientNet、ConvNeXt 等主干能够从眼底图像中提取出血、渗出和微动脉瘤等病灶特征。由于 DR 等级天然有序，QWK 通常比普通准确率更适合作为主评估指标。

2.2 DR 与 DME 联合建模

CANet 提出使用 cross-disease attention 同时进行 DR 与 DME 分级，其核心思想是先学习疾病特异特征，再用跨疾病依赖模块建模两种疾病间的相关性。本文借鉴这一思想，但在实现上采用更轻量的疾病特异注意力和通道门控式跨任务调制方法。

2.3 长尾学习与序数回归

Messidor 数据集中高风险 DR 与高风险 ME 样本显著少于阴性样本，普通交叉熵容易偏向多数类。LDAM 通过为少数类施加更大分类间隔改善长尾类别边界，DRW 则在训练后期启用类别重加权以避免早期特征学习被权重扰乱。另一方面，CORN /CORAL 将有序多分类转化为阈值二分类，能够减少远距离错分，与 QWK 目标更一致。

3.方法

3.1 任务定义

给定眼底图像 x ，模型同时预测两个标签：

$$y^{dr} \in \{0,1,2,3\}, \quad y^{me} \in \{0,1,2\}.$$

其中 y^{dr} 表示 DR 病变等级， y^{me} 表示黄斑水肿风险等级。训练目标为多任务监督学习：

$$\mathcal{L} = w_{dr} \mathcal{L}_{dr} + w_{me} \mathcal{L}_{me}.$$

本研究中 $w_{dr} = w_{me} = 1$ 。

3.2 网络结构

网络整体结构如图 1 所示，由共享主干、任务注意力和双分类头组成。




图 1 多任务联合分级网络结构。输入图像经 ConvNeXt-Tiny 提取共享特征后，分别由 DR 和 ME 的疾病特异注意力模块增强，再通过跨任务门控建模双向依赖，最终送入各自的分类头。

输入图像经过预处理后缩放为 512×512 。主干采用 ImageNet 预训练的 ConvNeXt-Tiny，输出特征图 $F \in \mathbb{R}^{C \times H \times W}$ 。随后分别为 DR 与 ME 构造疾病特异特征：

$$F_{dr} = A_{dr}(F), \quad F_{me} = A_{me}(F),$$

其中 A_{dr} 和 A_{me} 由通道注意力与空间注意力组成。

跨任务注意力使用另一任务的全局上下文生成通道门控：

$$\tilde{F}_{dr} = F_{dr} \odot g_{me}(\text{GAP}(F_{me})),$$

$$\tilde{F}_{me} = F_{me} \odot g_{dr}(\text{GAP}(F_{dr})).$$

最后，对 $\tilde{F}_{dr}$ 与 $\tilde{F}_{me}$ 分别进行全局平均池化，并送入 DR 头与 ME 头。

3.3 分类头与损失函数

3.3.1 CORN 序数头

对于 K 类有序标签，CORN 输出 $K-1$ 个 logits，分别预测条件阈值事件。最终预测由超过阈值的数量得到：

$$\hat{y} = \sum_{k=0}^{K-2} \mathbb{I}(p(y > k) > 0.5).$$

该头将等级顺序显式编码到预测形式中，适合优化 QWK。

3.3.2 Softmax+LDAM+DRW

softmax 头直接输出 K 类 logits，训练时使用 LDAM loss：

$$\mathcal{L}_{ldam} = -\log \frac{\exp(s(z_y - \Delta_y))}{\exp(s(z_y - \Delta_y)) + \sum_{j \neq y} \exp(s z_j)},$$

其中少数类具有更大 margin $\Delta_y \propto n_y^{-1/4}$ ， $s=30$ 为温度缩放因子。DRW 在第 5 个 epoch 后启用基于有效样本数的类别重加权，避免早期特征学习受类别权重干扰。

3.4 Binary-init 微调策略

我们设计了二阶段微调策略以改善分级边界初始化（图 2）。




图2 Binary-init 二阶段微调策略。第一阶段学习 0-vs-positive 边界，第二阶段仅继承共享主干和注意力模块参数，重新初始化分类头进行完整等级微调。

第一阶段将原始标签压缩为二分类：

$$y_{bin}^{dr} = I(y^{dr} > 0), \quad y_{bin}^{me} = I(y^{me} > 0).$$

模型仍使用共享主干和跨任务注意力，但两个任务头均改为二分类头。该阶段用 sensitivity 与 specificity 的平均值作为 early stopping 指标，目标是让共享表示先学习稳定的阴性/阳性二分类。

第二阶段丢弃二分类头，只加载第一阶段的 backbone、疾病特异注意力和跨任务注意力参数，重新初始化完整等级头，并在原始 DR 0-3 与 ME 0-2 标签上微调。该策略不改变最终推理流程，避免了 positive-only cascade 中 gate 错误无法修正的问题。

4. 实验设置

4.1 数据与划分

目标数据为 Messidor 数据集，共 1200 张眼底图像，同时包含 DR 0–3 和 ME 0–2 标签。实验采用五折交叉验证，每一折中当前 fold 作为 held-out 验证/测试折，其余 fold 用于训练。所有模型使用相同的 fold 划分以保证可比性。

预处理包括眼底图像裁剪、尺寸归一化到 512×512、训练期同步进行随机几何变换（旋转、镜像等）与颜色增强（图 3）。




图 3 经过统一裁剪、归一化处理以及颜色与对比度增强的眼底图示意。

4.2 训练细节

模型采用 AdamW 优化器，学习率 1×10^{-4} ，weight decay 0.05，训练 80 个 epoch，warmup 5 个 epoch，batch size 8，梯度累积 2（有效 batch size 16），启用混合精度与梯度 checkpoint。Early stopping patience 为 25 个 epoch。主要 early stopping 指标为：

$$balanced = \frac{1}{2} QWK_{mean} + \frac{1}{2} macro\ recall.$$

4.3 评估指标

主指标为 DR 与 ME 各自的 Quadratic Weighted Kappa (QWK)，并报告平均 QWK:

$$QWK_{mean} = \frac{1}{2}(QWK_{dr} + QWK_{me}).$$

辅助指标包括每类 recall、macro recall、accuracy，以及从完整等级预测派生出的 0-vs-positive sensitivity/specificity。综合评估指标 balanced 同时考虑有序一致性 (QWK) 与类别覆盖 (macro recall)。

5. 实验结果

5.1 主要结果

表 1 总结了四种方法在五折交叉验证上的平均结果。

方法	DR QWK	ME QWK	Macro Recall	Balanced
CORN+DRW	0.9096±0.015	0.8727±0.017	0.7709±0.024	0.8310±0.010
Softmax+LDAM+DRW	0.9028±0.016	0.8386±0.039	0.7851±0.041	0.8279±0.025
Binary-init → CORN	0.9072±0.024	0.8787±0.018	0.7837±0.024	0.8383±0.011
Binary-init → Softmax	0.9034±0.012	0.8416±0.013	0.7920±0.016	0.8323±0.008

表 1 五折交叉验证主要结果 ($mean \pm std$)。最优结果加粗。

CORN+DRW 基线在 DR QWK 上表现最高，体现了序数头对有序稳定性的优势。Softmax+LDAM+DRW 的 macro recall 更高，说明其对少数类和中间类更敏感，但 ME QWK 方差明显更大 (0.039 vs 0.017)，稳定性不足。Binary-init → CORN 在保持高 QWK 的同时显著提升了 ME QWK 和 balanced 指标，是当前最均衡的方案。Binary-init → Softmax 取得了最高的 macro recall，适合对阳性检出率要求更高的场景。

5.2 类别级召回分析

表 2 展示将五折汇总后的每类 recall，揭示各方法在不同等级上的行为差异。

5.2.1 五折汇总每类 recall

方法	DR0	DR1	DR2	DR3	ME0	ME1	ME2
CORN+DRW	0.943	0.458	0.705	0.831	0.977	0.600	0.834
Softmax+LDAM+DRW	0.907	0.516	0.615	0.858	0.950	0.787	0.775
Binary-init → CORN	0.934	0.529	0.700	0.819	0.970	0.640	0.841
Binary-init → Softmax	0.901	0.608	0.668	0.850	0.932	0.693	0.861

分析 recall 结果可得出以下结论：

- (1) Softmax+LDAM 相比 CORN 明显提升 DR1 (+5.8pp) 和 ME1 recall (+18.7pp)，但牺牲了 ME0 稳定性 (-2.7pp)。
- (2) Binary-init → CORN 相比 CORN 基线提升 DR1 recall (0.458→0.529)，并保持 ME2 高召回，说明二分类预训练确实改善了中间类别的边界学习；
- (3) Binary-init → Softmax 的 DR1 recall 达到 0.608，但 ME0 降至 0.932，体现更强的阳性倾向性和潜在假阳性风险。

5.3 Binary-init 边界学习效果

为验证 binary-init 策略的有效性，我们分析了第一阶段的二分类性能（表 3）。

5.3.1 Binary-init 第一阶段五折二分类性能（mean $\pm$ std）

任务	Sensitivity	Specificity	Binary Balanced
DR (0 vs 1-3)	0.888 $\pm$ 0.028	0.952 $\pm$ 0.013	0.934 $\pm$ 0.013
ME (0 vs 1-2)	0.942 $\pm$ 0.025	0.952 $\pm$ 0.008	

五折平均 binary balanced 达到 0.934，表明第一阶段确实学习到了稳定的阴性/阳性决策边界。完整等级微调后，Binary-init $\rightarrow$ CORN 的 pooled 0-vs-positive 指标为：DR sensitivity 0.898、specificity 0.934；ME sensitivity 0.894、specificity 0.970。与 CORN 基线（DR sensitivity 0.871、specificity 0.943）相比，binary-init 显著提升了阳性检出而仅轻微降低阴性准确率。

5.4 消融实验

为验证各设计选择的必要性，我们进行了多组消融实验（表 4）。

消融设置	QWK _{mean}	Macro Recall	Balanced	Δ Balanced
CORN+DRW（基线）	0.891 $\pm$ 0.009	0.771 $\pm$ 0.024	0.831 $\pm$ 0.010	—
去除 DRW（epoch 0 启用）	0.639 $\pm$ 0.366	0.619 $\pm$ 0.241	0.629 $\pm$ 0.302	-0.202
仅 QWK _{mean} early stop	0.892 $\pm$ 0.006	0.751 $\pm$ 0.024	0.821 $\pm$ 0.012	-0.010
Smooth margin schedule	0.868 $\pm$ 0.009	0.784 $\pm$ 0.025	0.826 $\pm$ 0.014	-0.005

表 4 消融实验结果（五折交叉验证）。 Δ 表示相对于 CORN+DRW 基线的变化。

各消融的具体分析如下：

5.4.1 去除 DRW

将 DRW 从 epoch 5 延迟改为 epoch 0 即刻启用后，五折方差剧增（balanced std 从 0.010 升至 0.302），部分 fold 完全崩溃。这表明过早引入类别重加权会严重干扰早期特征学习，DRW 的延迟策略在小样本长尾设置中不可或缺。

5.4.2 Early stopping 指标选择

仅以 QWK_{mean} 作为 early stopping 时， QWK_{mean} 本身相近（0.892 vs 0.891），但 macro recall 下降 2.0pp（0.771→0.751）。说明 balanced 指标能够在模型选择阶段兼顾有序一致性与类别覆盖，避免过度偏向多数类。

5.4.3 LDAM margin 调度方式

将 LDAM margin 从硬切换改为 smoothstep 平滑上升（5 epoch ramp）， QWK_{mean} 降低 0.023，balanced 降低 0.005。这可能因为平滑过渡削弱了 margin 在训练中后期的完整约束力度。本文最终采用硬切换。

5.4.4 Backbone 选择

我们在单 fold 上尝试将 ConvNeXt-Tiny 替换为 ResNet50，结果模型无法收敛（ $QWK < 0.01$ ），因此未进行完整五折验证。分析认为，ConvNeXt-Tiny 的大核卷积和 LayerNorm 设计在小数据多任务场景下提供了更好的特征正则化能力，而 ResNet50 在仅 1200 张图像上容易过拟合到多数类。

6. 可解释性分析

我们在 fold 0 上对同一批 held-out 图像导出 Grad-CAM 热力图，比较四种方法的注意力分布模式。图 4 和图 5 分别展示了 DR 和 ME 任务的典型案例。

图4 DR 任务 Grad-CAM 热力图对比 (fold 0 held-out 样本)




图4 DR 任务 Grad-CAM 热力图对比。Softmax+LDAM 系列（第 2、4 行）热力图更锐利且覆盖分散病灶，但在 DR0 样本中偶尔出现视盘区域误激活。CORN 系列（第 1、3 行）激活更弥散但更稳定。

图5 ME 任务 Grad-CAM 热力图对比 (fold 0 held-out 样本)




图5 ME 任务 Grad-CAM 热力图对比。Binary-init 系列（第3、4行）对黄斑区域的聚焦更集中，与其更高的ME QWK 一致。

定性分析中观察到如下两个稳定现象：

现象一：Softmax+LDAM 热力图更锐利

Softmax+LDAM 系列的 Grad-CAM 通常覆盖更小、更集中的区域，倾向于定位到具体病灶（微动脉瘤、出血点）。这与其更高的 DR1/DR2 召回一致——直接类别竞争和 LDAM margin 迫使模型学习更具判别力的局部特征。

现象二：视盘亮区误激活

在部分阴性或轻度样本中，Softmax+LDAM 出现视盘或视盘附近亮区的异常激活。由于眼底图像中视盘天然高亮且形态规则，该区域可能被模型误用为病变证据，导致 0-vs-positive 假阳性上升。相比之下，CORN 的激活更弥散、更保守，整体 QWK 和 ME0 稳定性更好。Binary-init 可以部分缓解该问题——经过第一阶段的 0-vs-positive 边界学习后，模型对视盘的敏感性有所降低。

7. 讨论

7.1 损失函数的互补性

实验清晰地展示了两类训练目标的权衡关系。CORN 将有序结构显式编码到预测形式中，天然适合 QWK 优化，但阈值式训练对相邻类别的直接区分约束较弱，尤其限制 DR1 和 ME1 等过渡类别的召回。Softmax+LDAM 直接优化类别竞争并通过 margin 强化少数类，能改善中间类召回，但缺少有序约束且更容易学习到视觉捷径。

两者的互补性提示，未来可以探索混合损失（如 CORN + 辅助 LDAM 约束）或自适应目标切换策略。

7.2 Binary-init 的作用机制

Binary-init 的核心价值不在于改变最终推理流程，而在于为共享表示提供更稳健的初始化。第一阶段的 0-vs-positive 学习简化了任务复杂度，使 backbone 和注意力模块能够聚焦于最基本的疾病/健康区分，而非一开始就面对细粒度等级区分的梯度竞争。实验表明该策略对 CORN 方向收益更大（balanced +0.7pp），可能因为 CORN 的阈值结构与二分类预训练的表达更为兼容。

7.3 训练稳定性与小样本长尾效应

DRW 消融实验反映了模型在小样本长尾场景下的脆弱性。在仅 1200 张图像的条件下，类别重加权的引入时机和方式对训练动态影响巨大。这解释了标准 ResNet 在极小数据量上因缺乏 ConvNeXt 的 LayerNorm 和卷积核带来的隐式正则化而更容易崩溃或过拟合。

8. 局限与未来工作

尽管在 Messidor 数据集上得到了较好的预测准确率与 recall，本文工作仍存在以下局限：

(1) 实验仅基于 Messidor 1200 张图像，外部泛化能力需在 Messidor-2、APTOS 等数据集上进一步验证；

(2) Grad-CAM 分析为定性观察，视盘激活与错误预测之间的因果关系有待量化验证；

(3) 当前未纳入像素级病灶监督。

后续工作方向包括：

(1) 构建视盘 mask，结合遮挡实验验证 softmax 对视盘等大结构的敏感性；

(2) 通过在部分区域加入掩模增强健壮性，降低 Softmax+LDAM 假阳性；

(3) 利用 MAPLES-DR 等像素级病灶数据集标注进行辅助监督；

(4) 探索 CORN 与 LDAM 的混合损失方案，兼顾有序性与类别敏感性。

9. 结论

本文实现并系统评估了用于 DR 与 DME 联合分级的多任务眼底图像识别系统。通过五折交叉验证和多组消融实验，我们得出以下结论：

(1) CORN 序数头与 Softmax+LDAM 分别代表有序稳定性和类别敏感性两种优势方向，两者互补；

(2) Binary-init 微调策略有效改善了共享表示的 0-vs-positive 边界，使 Binary-init+CORN 取得最佳综合性能（balanced 0.8383）；

(3) DRW 延迟重加权策略对小样本长尾场景的训练稳定性至关重要；

(4) ConvNeXt-Tiny 在 1200 样本条件下显著优于 ResNet50。Grad-CAM 可解释性分析进一步指出，未来提升的关键不仅在于增强病灶敏感性，更在于抑制视盘亮区等视觉捷径，在召回率与假阳性之间实现更稳健的平衡。

参考文献

- Li, X., Hu, X., Yu, L., Zhu, L., Fu, C.-W., & Heng, P.-A. CANet: Cross-disease Attention Network for Joint Diabetic Retinopathy and Diabetic Macular Edema Grading. *arXiv:1911.01376*, 2019.
- Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., & Xie, S. A ConvNet for the 2020s. *CVPR*, 2022.
- Cao, K., Wei, C., Gaidon, A., Arechiga, N., & Ma, T. Learning Imbalanced Datasets with Label-Distribution-Aware Margin Loss. *NeurIPS*, 2019.
- Shi, X., Cao, W., & Raschka, S. CORN – Conditional Ordinal Regression for Neural Networks. *Pattern Analysis and Applications*, 2023.
- Cao, W., Mirjalili, V., & Raschka, S. Rank Consistent Ordinal Regression for Neural Networks with Application to Age Estimation. *Pattern Recognition Letters*, 2020.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *ICCV*, 2017.
- Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. CBAM: Convolutional Block Attention Module. *ECCV*, 2018.
- Decencière, E., et al. Feedback on a Publicly Distributed Image Database: The Messidor Database. *Image Analysis & Stereology*, 2014.